

Detección de COVID-19 mediante radiografía de tórax usando Redes Neuronales Convolucionales

Gonzalez, Mauricio
Salse, Lucas Antonio

February 21, 2021

1 Introducción

Hoy en día con la situación actual en la que nos encontramos con respecto a la pandemia mundial del Coronavirus, tenemos la necesidad de poder diagnosticar lo más pronto posible si una persona es portadora o no de la enfermedad. Esto se debe a que por el momento el método de prueba aprobado por la OMS es el método de reacción en cadena de la polimerasa de transmisión inversa (RT-PCR), en el que las secuencias cortas de ADN o ARN se analizan. Sin embargo, algunas personas requieren más de una prueba para descartar la posibilidad de contagio. Como sabemos la disponibilidad limitada de áreas de trabajo de detección y kits de prueba para detectar COVID-19 crea una enorme carga para los profesionales médicos y el personal para manejar la situación. Es en este escenario que la detección rápida y precisa de casos sospechosos de COVID-19 es un gran desafío al cual enfrentarse. El aumento exponencial de casos también plantea la necesidad de múltiples pruebas para tener una idea de la situación real, como evoluciona la pandemia en ciertas regiones y tomar la decisión adecuada en consecuencia.

Debido también al costo de dichas pruebas de detección y no solo a la escasez es que se buscan nuevos métodos alternativos como es el caso de las pruebas de rayos X para la detección de la enfermedad. Son una modalidad que se utiliza con frecuencia para diagnosticar la neumonía con el hecho de que el sistema de imágenes de rayos X es una parte esencial de la atención médica en todo el mundo. Sumándole a esto la fácil disponibilidad de las máquinas de rayos X hace que sea mucho más accesible para las diferentes regiones. También puede haber ciertos casos en los que los pacientes obtuvieron imágenes por otras razones y sus exploraciones revelaron hallazgos potencialmente sugestivos de COVID-19.

2 Objetivo

El objetivo de este trabajo es poder llevar a cabo un aprendizaje supervisado mediante Redes Neuronales Convolucionales (CNN) y diferentes imágenes de rayos X de tórax (dataset),

para predecir un resultado lo suficientemente acertado de que si un individuo tiene COVID-19, posee una neumonía viral o se encuentra saludable.

3 Datos utilizados

Los datos fueron obtenidos de la plataforma Kaggle, la cual es una comunidad online de científicos de datos, ingenieros de deep learning y profesionales de machine learning. En donde se lleva a cabo ciertas competencias con premios para resolver ciertos problemas en esta área.




Figure 1: Clases de los dataset

3.1 Datos obtenidos:

- Imágenes de COVID : 1200
- Imágenes de NORMAL : 1341
- Imágenes de NEUMONÍA VIRAL: 1345

Como se puede observar los datos se encuentran bastante balanceados para el aprendizaje de nuestro modelo de red neuronal. De estos datos el 20% fueron utilizados para llevar a cabo la validación.

4 Herramientas utilizadas

Se tuvo en cuenta que las imágenes no siempre se encuentran disponibles de la misma forma, por lo tanto se procedió a realizar aumentación de datos para generar imágenes levemente modificadas, utilizando ciertos parámetros como:

- Rotación
- Zoom
- Desplazamiento horizontal
- Desplazamiento vertical

Con estas imágenes fue que se entrenó el modelo, y se utilizó además, la librería **callbacks** de Keras. Estos callbacks determinan cual es el mejor desempeño del modelo y cortan de forma automática el entrenamiento cuando se alcanza la máxima precisión con el menor error posible. Otra herramienta utilizada fue **Matplotlib** que es una biblioteca para la generación de gráficos a partir de datos contenidos en vectores, la cual nos ayudó a visualizar las curvas de aprendizaje del modelo durante la etapa de entrenamiento. Por último, utilizamos una Matriz de Confusión, que permite evaluar de manera visual las predicciones generadas por nuestro modelo.




Figure 2: Gráficos de aprendizaje durante el entrenamiento




Figure 3: Comparación entre etiquetas reales y predecidas

5 Conclusiones

Se consiguió construir una red neuronal tal que su precisión sobre el dataset de test fue bastante alta (96% aprox.). Esto fue debido a que contamos con una buena calidad de imágenes de entrada (además de estar bien balanceadas); tanto la complejidad de la red y el tiempo de entrenamiento fueron correctos. En las gráficas de las curvas de aprendizaje se ve claramente que obtuvimos el máximo valor de accuracy posible sin generar overfitting. Luego, mediante la matriz de confusión confirmamos que la cantidad de falsos positivos/negativos era muy baja, mientras que los valores en la diagonal principal (coincidencias entre etiquetas reales y etiquetas predecidas) eran muy altos. A continuación se muestra la salida del modelo con su correspondiente predicción.




Figure 4: Predicción del modelo sobre tres radiografías de prueba